



QBC13_AI_Project 1

آمار توصیفی (q1 to q9)

1 توزیع آگهی های موجود در دسته های مختلف را برای دسته بندی سطح دو و سطح سه رسم کنید.




بیشترین تعداد آگهی (55.8٪) مربوط به دسته **فروش مسکونی** (residential-sell) است که اختلاف زیادی با سایر دسته ها دارد. بعد از آن، **اجاره مسکونی** (residential-rent) بیشترین سهم را با 27.6٪ دارد. این موضوع نشان می دهد بخش بزرگی از داده های موجود مربوط به معاملات مسکونی است، در حالی که دسته های تجاری و خدماتی تعداد کمتری آگهی دارند.




بیشترین آگهی‌ها در دسته‌بندی سطح 3 مربوط به **فروش آپارتمان با 33.3%** و **اجاره آپارتمان با 21.18%** است که این دو دسته به‌تنهایی بخش قابل‌توجهی از آگهی‌ها را به خود اختصاص داده‌اند.

2. هیستوگرام سال ساخت را رسم کنید.



رسم نمودار بدون هندل کردن داده‌های نال یا ستون‌های هدف.




با رسم هیستوگرام سال ساخت، توزیع آگهی‌ها در سال‌های مختلف بررسی شد. در توزیع کل داده‌ها، فراوانی آگهی‌های مربوط به سال‌های ساخت جدیدتر بیشتر است و بیشترین تعداد آگهی‌ها در سال‌های انتهایی بازه، به‌ویژه سال ۱۴۰۳، مشاهده می‌شود.

اما به‌خاطر تعداد بالای داده‌های Missing شده در ستون سال ساخت، اول تصمیم داشتم با استفاده از ستون‌های title و description داده‌های Missing شده را در صورت موجود بودن، از روی توضیحات استخراج کنم.

مابین کار متوجه شدم که اکثر Missing Value ها اصلاً به آگهی‌های فروش ملک مسکونی مربوط نمی‌شوند و بیشتر در دسته‌های مشارکت املاک یا اجاره‌های موقت بودند. برای همین تصمیم گرفتم داده را محدود کنم به آگهی‌های مربوط به آپارتمان، خانه و ویلا در حالت فروش یا اجاره.


شکل کلی توزیع تغییر محسوسه نکرده و الگوی مشابهی مشاهده شد. این موضوع با توجه به اینکه این دسته‌ها بخش بزرگی از داده‌های اولیه را تشکیل می‌دهند، قابل انتظار است.

3. تعداد آگهی‌های منتشرشده در ماه‌های مختلف را برای فروش و اجاره بررسی کنید. آیا تعداد آگهی‌های فروش و اجاره در زمان‌های مشخصی از سال افزایش چشمگیری داشته است؟




مشخص است که تعداد آگهی‌ها به‌طور کلی با نزدیک شدن به فصل تابستان افزایش چشمگیری دارد. سپس آگهی‌های مربوط به بخش فروش تقریباً یک ترند ثابت را می‌پیمایند و آگهی‌های مربوط به اجاره در فصل پاییز به اوج می‌رسند.


4. توزیع قیمت فروش (price_value) را برای دسته‌بندی‌های سطح سه در یک نمودار رسم کنید.



توزیع قیمت فروش برای زیرمجموعه‌های سطح سه، فقط مربوط به آگهی‌های فروش.



توزیع قیمت برای زیرمجموعه‌های سطح سه، فقط مربوط به آگهی‌های اجاره، پس از تبدیل مقیاسی اجاره و رهن به قیمت قابل قیاس.




توزیع قیمت با استفاده از قیمت‌های تبدیل‌شده، به‌طور کلی در دسته‌بندی‌های فروش و اجاره.

این نمودار توزیع **قیمت قابل‌مقایسه** (`price_comparable`) را در دسته‌های مختلف املاک نشان می‌دهد. در هر دسته، قیمت آگهی‌های فروش (آبی) و اجاره (نارنجی) با استفاده از نمودار جعبه‌ای مقایسه شده‌اند.

خط داخل هر جعبه نشان‌دهنده میانه قیمت و محدوده جعبه بیانگر ۵۰٪ میانی داده‌ها است. خطوط بیرونی محدوده قیمت‌های معمول را نشان می‌دهند و نقاط خارج از این محدوده به‌عنوان داده‌های پرت نمایش داده شده‌اند.

نمودار نشان می‌دهد که توزیع و پراکندگی قیمت در دسته‌های مختلف متفاوت است و برخی دسته‌ها دارای تعداد قابل‌توجهی داده پرت با قیمت‌های بسیار بالا هستند.


5. بر روی نقشه جغرافیایی Heatmap آگهی‌های هر منطقه را رسم کنید. تراکم آگهی‌ها در کدام منطقه بیشتر است؟




واضح است که تراکم آگهی‌ها در کلان‌شهرها بیشتر و در تهران و اطراف تهران بسیار زیاد است و این تراکم در شهرهای کوچک‌تر کمتر می‌شود. QBC13_AI_Project 1(2)

6. ترند میانگین قیمت اجاره بر حسب ماه‌های قرار گرفتن آگهی‌ها رسم کنید.

دقت کنید که ماه‌ها باید به تاریخ شمسی و خوانا باشند.




7. در طول زمان قیمت‌های اسمی افزایش پیدا می‌کنند، اما این افزایش لزوماً به معنی بالا رفتن ارزش واقعی ملک نیست و می‌تواند ناشی از تورم باشد. به ازای میانگین مبلغ قیمت (value_price) در سال‌های ۱۴۰۰ تا ۱۴۰۳ قیمت حقیقی را محاسبه کنید و بررسی کنید ترند قیمت حقیقی چگونه است؟



شاخص مورد استفاده، **شاخص کل قیمت مصرف‌کننده کل خانوارهای کشور** با سال پایه $1400 = 100$ است. شاخص مسکن یا نرخ تورم نقطه‌به‌نقطه جایگزین CPI کل نشده است.

از میانگین سالانه CPI استفاده می‌کنیم، نه شاخص اسفند. شاخص‌های ۱۴۰۰ تا ۱۴۰۲ از جدول ۷ گزارش مرکز آمار و شاخص ۱۴۰۳ از میانگین ۱۲ مقدار ماهانه همان مجموعه، با گرد کردن به یک رقم اعشار، گرفته شده‌اند.

شاخص سال ۱۴۰۳ برابر $271,7$ است؛ $215,7$ شاخص اسفند است و میانگین سالانه نیست.



میانگین حساسی به قیمت‌های بسیار بزرگ حساس است. در کنار پاسخ اصلی، میانه حقیقی و میانگین پس از وینزور ۱٪ گزارش می‌شوند.

وینزور یعنی مقادیر کمتر از صدک ۱ یا بیشتر از صدک ۹۹ را به همان آستانه برسانیم؛ ردیف‌ها حذف نمی‌شوند. برای مقایسه سال‌ها، آستانه مشترک از قیمت‌های اسمی تمام چهار سال محاسبه می‌شود.

این یک تحلیل حساسیت با معیار تغییر یافته است، نه اثبات اشتباه بودن قیمت‌های خارج از آستانه و نه جایگزین مخفی میانگین اصلی. همچنین برای حساسیت به ابهام تاریخ ماهانه، میانگین با حذف مارس محاسبه می‌شود.

میانگین حقیقی در این نمونه از ۱۴۰۰ به ۱۴۰۱ افزایش، در ۱۴۰۲ کاهش و در ۱۴۰۳ دوباره افزایش دارد؛ روند یکنواخت نیست.


برای ۱۴۰۰ فقط ۳ آگهی و برای ۱۴۰۱ فقط ۴۷ آگهی فروش قیمت‌دار وجود دارد؛ تقریباً تمام حجم نمونه در ۱۴۰۳ است.

اختلاف بزرگ میانگین و میانه و تغییر نتیجه با کنترل مقادیر افراطی، حساسیت به کیفیت داده را نشان می‌دهد. از ۱۴۰۲ به ۱۴۰۳، برخلاف میانگین خام، میانه حقیقی و میانگین حقیقی وینزور شده کاهش پیدا می‌کنند.

بنابراین این نمودار روند میانگین آگهی‌های همین فایل را نشان می‌دهد و مبنای کافی برای ادعای رشد واقعی کل بازار مسکن ایران نیست. ترکیب شهر، نوع ملک، متراژ و

ماه‌های مشاهده‌شده ثابت نگه داشته نشده است و مبلغ آگهی نیز قیمت معامله
قطعی نیست.

8. ماتریس همبستگی را برای مبلغ قیمت، متراژ زمین، زیربنا، ظرفیت نفرات، تعداد اتاق‌ها و طول و عرض جغرافیایی رسم نمایید.



هفت متغیر در ماتریس وجود دارد: مبلغ قیمت، متراژ زمین، زیربنا، ظرفیت معمول نفرات، تعداد اتاق، طول جغرافیایی و عرض جغرافیایی.


«ظرفیت نفرات» به ستون `capacity_person_regular` نگاشت شده است؛ ظرفیت اضافه به آن جمع نشده است.

ماتریس اصلی **Pearson** است و **Spearman** برای بررسی حساسیت به مقادیر پرت و روابط یکنواخت ارائه می‌شود.

برای هر جفت متغیر فقط ردیف‌هایی به کار می‌روند که همان دو مقدار موجود باشند (`pairwise complete observations`). شرط حداقل ۳۰ مشاهده برای گزارش ضریب اعمال می‌شود؛ همه جفت‌های قابل گزارش در این داده بسیار بیشتر از این تعداد مشاهده دارند.

ظرفیت نفرات در اجاره موقت ثبت شده، ولی قیمت فروش معتبر در آگهی‌های فروش است؛ هیچ همپوشانی معتبری بین این دو وجود ندارد. بین ظرفیت نفرات و متراژ زمین نیز همپوشانی وجود ندارد.

این خانه‌ها NA هستند، نه صفر. حذف همه ردیف‌هایی که یکی از هفت متغیرشان خالی باشد، کل نمونه را از بین می‌برد.



در Pearson، همبستگی زمین و زیربنا حدود ۰,۳۷۳ و همبستگی ظرفیت نفرات و تعداد اتاق حدود ۰,۳۴۴ است.

همبستگی خام قیمت و زیربنا حدود ۰,۰۵۲ و قیمت و تعداد اتاق حدود ۰,۰۱۴ است؛ این اعداد به تنهایی نبود رابطه را ثابت نمی‌کنند.


در Spearman، قیمت و تعداد اتاق حدود ۰,۴۱۵، زیربنا و تعداد اتاق حدود ۰,۶۴۶ و زیربنا و ظرفیت نفرات حدود ۰,۴۹۷ هستند.



اختلاف دو روش با حضور داده‌های افراطی و شکل غیرخطی رابطه سازگار است.


هر جفت ضریب ممکن است بر زیرجمعیت متفاوتی از آگهی‌ها محاسبه شده باشد؛ جدول تعداد مشاهدات برای همین منظور همراه نتیجه است. تعداد اتاق‌ها متغیر سقف‌گذاری شده است.



ضریب پایین قیمت با طول و عرض جغرافیایی هم به معنای بی‌اهمیت بودن مکان نیست؛ اثر شهر و محله را نمی‌توان با یک رابطه خطی سراسری با مختصات خلاصه کرد. همبستگی نیز رابطه علّی را اثبات نمی‌کند.


9. می‌خواهیم بررسی کنیم خانه‌هایی که دارای بالکن، آسانسور، نگهبان، باربیکیو و استخر هستند عمدتاً در کدام مناطق قرار دارند. با نمودار مناسب این موضوع را نشان دهید.












آزمون فرض (h1 to h4)

با توجه به رشد مهاجرت افراد از شهرهای کوچکتر به کلان‌شهرها و تراکم جمعیت در این نواحی، تصور می‌شود که میانگین مساحت خانه‌های مسکونی در کلان‌شهرها نسبت به شهرهای کوچک و روستاها کمتر است.

آیا مجموعه داده این فرضیه را پشتیبانی می‌کند؟



در این تحلیل، متراژ ساختمان (`size_building`) بین دو گروه **کلان‌شهرها** و **شهرهای کوچک** مقایسه شده است. ابتدا برای کاهش تأثیر داده‌های پرت، با استفاده از روش IQR داده‌های پرت حذف شدند. سپس برای هر گروه، میانگین متراژ ساختمان محاسبه و دو آزمون آماری انجام شد.

در گروه کلان‌شهرها، میانگین متراژ ساختمان حدود **98.81 مترمربع** و در شهرهای کوچک حدود **104.58 مترمربع** به دست آمد. بنابراین، میانگین متراژ ساختمان در شهرهای کوچک در این نمونه بیشتر است.

در آزمون **Welch's t-test**، فرض صفر این بود که میانگین متراژ ساختمان در کلان‌شهرها بزرگ‌تر یا مساوی شهرهای کوچک است:

$$t\text{-statistic} = -54.87$$

$p\text{-value} < 0.001$

از آنجا که مقدار $p\text{-value}$ بسیار کمتر از سطح معناداری 0.05 است، فرض صفر رد می‌شود و شواهد آماری از این فرض حمایت می‌کند که میانگین متراژ ساختمان در کلان‌شهرها کمتر از شهرهای کوچک است.

برای بررسی بیشتر، آزمون **Mann–Whitney U** نیز انجام شد که به توزیع نرمال داده‌ها وابستگی کمتری دارد. نتیجه این آزمون نیز معنادار بود:


$$U\text{-statistic} = 76,114,024,716.5$$
 $p\text{-value} < 0.001$

بنابراین، هر دو آزمون نتیجه یکسانی ارائه می‌دهند: در داده‌های مورد بررسی، ساختمان‌های موجود در کلان‌شهرها به‌طور آماری معناداری متراژ کمتری نسبت به ساختمان‌های شهرهای کوچک دارند.

«قدیمای خانه‌ها دلبازتر بود!»

برای بررسی این فرضیه، آیا میانگین مساحت خانه‌های قدیمی‌ساخت نسبت به خانه‌های جدیدساخت بیشتر است؟

خانه‌های قدیمی‌ساخت را خانه‌هایی در نظر بگیرید که قبل از سال ۹۶ ساخته شده‌اند.



در این تحلیل، مترآژ ساختمان (`size_building`) بین دو گروه خانه‌های قدیمی‌ساخت و خانه‌های جدیدساخت مقایسه شده است.

خانه‌هایی که سال ساخت آن‌ها کمتر از ۱۳۹۶ بوده در گروه قدیمی و خانه‌هایی با سال ساخت ۱۳۹۶ و بعد از آن در گروه جدید قرار گرفته‌اند.

برای کاهش تأثیر داده‌های پرت، ابتدا برای هر گروه به‌صورت جداگانه از روش IQR استفاده شد و مقادیر خارج از محدوده زیر حذف شدند:

$$1.5 \times IQR$$

نتایج توصیفی نشان می‌دهد که میانگین مترآژ خانه‌های قدیمی‌ساخت حدود **91.01 مترمربع** و میانگین مترآژ خانه‌های جدیدساخت حدود **110.68 مترمربع** است.

همچنین میانه مترآژ در خانه‌های قدیمی **85 مترمربع** و در خانه‌های جدید **104 مترمربع** است.

بنابراین، در داده‌های نمونه، خانه‌های جدیدساخت به‌طور متوسط مترآژ بیشتری دارند.

برای بررسی آماری این تفاوت، آزمون **Mann-Whitney U** به دلیل غیرنرمال بودن توزیع داده‌ها انجام شد.

فرض‌ها به شکل زیر تعریف شدند:

H₀: میانگین یا موقعیت توزیع متراژ خانه‌های قدیمی‌ساخت بزرگ‌تر یا مساوی خانه‌های جدیدساخت است.

H₁: متراژ خانه‌های قدیمی‌ساخت بیشتر از خانه‌های جدیدساخت است.

نتیجه آزمون:

U-statistic = 37,123,786,259

p-value = 1.00

از آنجا که مقدار p-value بسیار بزرگ‌تر از سطح معناداری 0.05 است، فرض صفر رد نمی‌شود.

در واقع، جهت اختلاف مشاهده‌شده کاملاً برخلاف فرض جایگزین است؛ یعنی داده‌ها نشان می‌دهند متراژ خانه‌های قدیمی‌ساخت کمتر از خانه‌های جدیدساخت است.

برای بررسی تکمیلی، آزمون **Welch's t-test** نیز انجام شد و نتیجه آن نیز با این مشاهده سازگار بود:

t-statistic = -212.18

p-value = 1.00

برای آزمون یک‌طرفه با فرض:


old > new

بنابراین، در داده‌های مورد بررسی شواهد آماری از این فرض که خانه‌های قدیمی‌ساخت متراژ بیشتری از خانه‌های جدیدساخت دارند وجود ندارد.

برعکس، آمار توصیفی نشان می‌دهد که خانه‌های جدیدساخت در این نمونه به‌طور محسوسی متراژ بیشتری دارند.

داشتن سند تجاری، یا هر نوع سند ملکی، در املاک به این معنی است که سند مالکیت معتبر، رسمی و قانونی برای ملک تجاری دارید. این سند نشان می‌دهد که شما صاحب قانونی ملک تجاری هستید و می‌توانید از حقوق مالکیت آن استفاده کنید.

بررسی کنید که آیا داشتن سند تجاری (deed_business_has) بر میانگین قیمت فروش ملک تجاری ارتباط معناداری دارد؟



در این فرضیه بررسی شد که آیا وضعیت سند تجاری (deed_business) با قیمت آگهی‌های فروش املاک تجاری ارتباط دارد یا خیر.

برای این منظور، آگهی‌های مربوط به sell-commercial با قیمت مثبت انتخاب شدند و آگهی‌هایی که وضعیت سند آنها نامشخص بود از تحلیل حذف شدند.

در نهایت، قیمت املاک دارای سند تجاری و فاقد سند تجاری با استفاده از آزمون **Welch's t-test** مقایسه شد.

سطح معناداری آزمون برابر با ۰,۰۵ در نظر گرفته شد. نتیجه آزمون نشان داد که مقدار p-value برابر با **۰,۸۷۹۵** است:

$$p = 0.8795 > 0.05$$

در سطح معناداری ۵ درصد، شواهد کافی برای رد فرض صفر وجود ندارد. بنابراین، در این نمونه تفاوت آماری معناداری بین میانگین قیمت آگهی‌های دارای سند تجاری و فاقد

سند تجاری مشاهده نشد.

همچنین برای بررسی تأثیر مقادیر پرت، یک تحلیل حساسیت با **Winsorization** در محدوده صدک‌های ۱ و ۹۹ انجام شد.

این بررسی به دلیل وجود مقادیر بسیار بزرگ در قیمت‌ها انجام گرفت؛ برای مثال، بیشترین قیمت ثبت‌شده در داده حدود **۱۰۰ تریلیون تومان** بود. بنابراین بررسی پایداری نتیجه نسبت به مقادیر حدی اهمیت داشت.

در مجموع، بر اساس آزمون انجام‌شده، داده‌های این نمونه شواهد آماری کافی برای وجود تفاوت در میانگین قیمت املاک تجاری بر اساس وضعیت سند تجاری ارائه نمی‌کنند.

این نتیجه به معنای اثبات برابری واقعی قیمت دو گروه نیست، بلکه نشان می‌دهد که با این داده‌ها و در سطح معناداری ۰,۰۵، تفاوت مشاهده‌شده از نظر آماری معنادار نیست.

QBC13_AI_Project 1(2)

در دسته‌بندی امکانات موجود در آگهی‌ها می‌توانیم آن‌ها را به دو دسته امکانات لاکچری (**استخر، باربیکیو، سونا، جکوزی**) و امکانات غیرلاکچری تقسیم کنیم.

فرضیه ما این است که میانگین مبلغ قیمت برای وجود ویژگی‌های لاکچری افزایش چشمگیری دارد. اما آیا این میانگین برای وجود امکانات غیرلاکچری نیز تفاوت معناداری دارد؟

h4

از هر گروه ۵۰۰۰ نمونه به صورت تصادفی انتخاب شد.

ابتدا برای بررسی نرمال بودن توزیع قیمت‌ها از آزمون **Shapiro-Wilk** استفاده شد.

مقدار p-value برای گروه لوکس برابر با:

$$1.9983 \times 10^{-95}$$

و برای گروه غیرلوکس برابر با:

$$1.1322 \times 10^{-95}$$

به دست آمد.

از آنجا که هر دو مقدار بسیار کمتر از سطح معناداری ۰,۰۵ هستند، فرض نرمال بودن توزیع قیمت‌ها رد شد.

بنابراین، برای مقایسه دو گروه از آزمون ناپارامتری **Mann-Whitney U** استفاده شد.

فرضیه‌ها به صورت زیر تعریف شدند:

H₀: توزیع قیمت املاک لوکس بیشتر از توزیع قیمت املاک غیرلوکس نیست.

H₁: توزیع قیمت املاک لوکس بالاتر از توزیع قیمت املاک غیرلوکس است.

نتیجه آزمون:

$$U = 15,112,245.5$$

$$p\text{-value} = 1.6567 \times 10^{-73}$$

از آنجا که مقدار p-value بسیار کمتر از ۰,۰۵ است، فرض صفر رد می‌شود.

بنابراین، در این نمونه شواهد آماری معناداری وجود دارد که نشان می‌دهد توزیع قیمت املاک دارای حداقل یکی از امکانات لوکس، بالاتر از توزیع قیمت املاک فاقد این امکانات است. QBC13_AI_Project 1(2)

مسئله ۱: ساخت سیستم توصیه‌گر (p1 to p3)


بخش ۱

حال الگوریتم خوشه‌بندی **K-Means** را با ۱۰ خوشه برای این مجموعه داده اجرا کنید.


سپس ابتدا مختصات جغرافیایی را به فرمت **UTM** درآورد و برای دو ویژگی قیمت و مختصات UTM یک Scatter Plot رسم کنید.

بر روی Scatter Plot رسم‌شده مشخص کنید کدام نقاط مربوط به کدام خوشه هستند و مرکز هر خوشه را نیز رسم کنید.


به انتخاب رنگ، مارکر، نام‌گذاری محورها و به‌طور کلی قابل‌درک بودن تصویر دقت داشته باشید.




کلاستربندی جامع



کلاستربندی مربوط به داده‌های فقط مربوط به اجاره



کلاستربندی مربوط به داده‌های فقط مربوط به فروش




کلاستربندی مربوط به داده‌های فقط مربوط به اجاره روزانه

بخش ۲

پس از آن الگوریتم **K-Means** را برای K های ۱ تا ۲۰ اجرا کرده و با محاسبه مجموع مجذورات درون خوشه‌ای (**Within-Cluster Sum of Squares**) مقدار مناسبی برای هاپیرپارامتر K انتخاب کنید.


توجه کنید که بخش زیادی از نمره این بخش مربوط به نحوه انتخاب مقدار K است و چنانچه روش‌های تدریس‌شده و معمول پاسخگوی حل مسئله نبود، انتظار می‌رود با جست‌وجو و مطالعه بیشتر، روشی مناسب برای رفع چالش‌های احتمالی پیشنهاد دهید.



مقدار WCSS برای تعداد خوشه‌های مختلف، از ۱ تا ۲۰، محاسبه شده است. با افزایش تعداد خوشه‌ها، WCSS همیشه کاهش پیدا می‌کند؛ اما نکته مهم این است که بعد از یک نقطه، اضافه کردن خوشه‌های بیشتر بهبود زیادی ایجاد نمی‌کند.

در نمودار، این تغییر شیب یا همان **Elbow (آرنج)** تقریباً در محدوده $K = 8$ تا $K = 9$ دیده می‌شود.

بنابراین روش Elbow پیشنهاد می‌کند که تعداد خوشه‌ها حدود ۸ یا ۹ باشد.



روش دوم، **Silhouette Score** است که میزان مناسب بودن جداسازی خوشه‌ها را بررسی می‌کند.

مقدار Silhouette معمولاً بین **-1** و **1+** قرار دارد و مقدار بالاتر نشان‌دهنده جداسازی بهتر و ساختار مناسب‌تر خوشه‌ها است.


طبق نمودار:


در **K = 9** مقدار Silhouette حدود **0.182** است و بیشترین مقدار را دارد.

در **K = 8** مقدار آن حدود **0.166** است.

بنابراین، بر اساس Silhouette Score، مقدار **K = 9** بهترین مقدار است.

مثال کلاستر بندی ۸ تایی





با افزایش ϵ ، تعداد خوشه‌ها عموماً کاهش می‌کند، زیرا نقاط بیشتری به یکدیگر متصل می‌شوند.

همچنین با افزایش $\min_samples$ ، تشکیل خوشه سخت‌تر شده و تعداد خوشه‌های شناسایی‌شده معمولاً کاهش می‌یابد.

در مقادیر بسیار کوچک ϵ ، تعداد زیادی خوشه کوچک ایجاد می‌شود، در حالی که در مقادیر بزرگ مانند $\epsilon = 0.7$ و $\epsilon = 0.8$ تقریباً تمام داده‌ها به یک یا دو خوشه متصل می‌شوند.

در تنظیم:

$\epsilon = 0.5$


$\min_samples = 10$

الگوریتم DBSCAN سه خوشه شناسایی کرده است که برای بررسی تفاوت‌های مکانی و قیمتی بین گروه‌های املاک مورد استفاده قرار گرفته‌اند.


مسئله ۲: پیش‌بینی (f1 to f7)



توضیح ستون هدف که مقدار قابل مقایسه برای فروش اجاره رهن هست بدون log



ستون هدف با log



توزیع بعد از حذف outlier ها

