



QBC13_AI_Project 1

آمار توصیفی (q1 to q9)

1. توزیع آگهی‌های موجود در دسته‌های مختلف را برای دسته‌بندی سطح دو و سطح سه رسم کنید.




بیشترین تعداد آگهی (55.8%) مربوط به دسته residential-sell (فروش مسکونی) است که اختلاف زیادی با سایر دسته‌ها دارد. بعد از آن residential-rent (اجاره مسکونی) بیشترین سهم را دارد (با 27.6%). این موضوع نشان می‌دهد بخش بزرگی از داده‌های موجود مربوط به معاملات مسکونی است، در حالی که دسته‌های تجاری و خدماتی تعداد کمتری آگهی دارند.




بیشترین آگهی ها در دسته بندی سطح 3 مربوط به فروش آپارتمان با 33.3% ، اجاره آپارتمان با 21.18% است که این دو دسته به تنهایی بخش قابل توجه ای از آگهی ها را به خود اختصاص دادن .

2. هیستوگرام سال ساخت را رسم کنید.




رسم نمودار بدون هندل کردن داده های نال یا ستون های هدف



با رسم هیستوگرام سال ساخت، توزیع آگهی‌ها در سال‌های مختلف بررسی شد. در توزیع کل داده‌ها، فراوانی آگهی‌های مربوط به سال‌های ساخت جدیدتر بیشتر است و بیشترین تعداد آگهی‌ها در سال‌های انتهایی بازه، به‌ویژه سال ۱۴۰۳، مشاهده می‌شود. اما بخاطر تعدا بالای دیتا های miss شده در ستون سال ساخت اول تصمیم داشتم که با استفاده از ستون title و description داده های miss شده رو از روی توضیحات در صورت موجود بودن استخراج کنم که ما بین کار متوجه شدم که اکثر missing value ها اصلا به آگهی های فروش ملک مسکونی مربوط نمیشوند و بیشتر در دسته های مشارک املاک یا اجاره های موقت بودن برای همین تصمیم گرفتم که داده رو محدود بکنم به آگهی های مربوط به آپارتمان و خانه و ویلا در حالت فروش یا اجاره.


شکل کلی توزیع تغییر محسوسه نکرده و الگوی مشابهی مشاهده شده. این موضوع با توجه به اینکه این دسته‌ها بخش بزرگی از داده‌های اولیه را تشکیل می‌دهند قابل انتظار است.

3. تعداد آگهی‌های منتشر شده در ماه‌های مختلف را برای فروش و اجاره بررسی کنید. آیا تعداد آگهی‌های فروش و اجاره در زمان‌های مشخصی از سال افزایش چشمگیری داشته است؟




مشخص است که تعداد آگهی‌ها به طور کلی با نزدیک شدن به فصل تابستان افزایش چشمگیری دارد سپس آگهی‌های مربوط به بخش فروش یک ترند ثابتی رو تقریباً می‌پیماید و آگهی‌های مربوط به اجاره در فصل پاییز به اوج می‌رسد


4. توزیع قیمت فروش (price_value) را برای دسته‌بندی‌های سطح سه در یک نمودار رسم کنید.



توزیع قیمت فروش برای زیر مجموعه های سطح سه فقط مربوط به آگهی های فروش




توزیع قیمت فروش برای زیر مجموعه های سطح سه فقط مربوط به آگهی های اجاره پس
از تبدیل مقیاسی اجاره و رهن به قیمت قابل قیاس



توزیع قیمت فروش با استفاده از قیمت های تبدیل شده به طور کلی در دسته بندی های فروش و اجاره


این نمودار توزیع **قیمت قابل مقایسه (comparable_price)** را در دسته های مختلف املاک نشان می دهد. در هر دسته، قیمت آگهی های **فروش (آبی)** و **اجاره (نارنجی)** با استفاده از نمودار جعبه ای مقایسه شده اند. خط داخل هر جعبه نشان دهنده **میان قیمت** و محدوده جعبه بیانگر ۵۰٪ میانی داده ها است. خطوط بیرونی محدوده قیمت های معمول را نشان می دهند و نقاط خارج از این محدوده به عنوان **داده های پرت** نمایش داده شده اند. نمودار نشان می دهد که توزیع و پراکندگی قیمت در دسته های مختلف متفاوت است و برخی دسته ها دارای تعداد قابل توجهی داده پرت با قیمت های بسیار بالا هستند.

5. بر روی نقشه‌ی جغرافیایی heatmap آگهی‌های هر منطقه را رسم کنید. تراکم آگهی‌ها کدام منطقه بیشتر است؟




واضح است که تراکم آگهی‌ها در کلان‌شهرها بیشتر و در تهران و اطراف تهران بسیار زیاد است و این تراکم در شهرهای کوچک‌تر کمتر می‌شود

6. ترند میانگین قیمت اجاره بر حسب ماه‌های قرار گرفتن آگهی‌ها رسم کنید. (دقت کنید که ماه‌ها باید به تاریخ شمسی و خوانا باشند.)




7. در طول زمان قیمت‌های اسمی افزایش پیدا می‌کنند اما این افزایش لزوماً به معنی بالارفتن ارزش واقعی ملک نیست و می‌تواند ناشی از تورم باشد. به ازای میانگین مبلغ قیمت (price_value) در سال‌های ۱۴۰۰ تا ۱۴۰۳ قیمت حقیقی را محاسبه کنید و بررسی کنید ترند قیمت حقیقی چگونه است؟



شاخص مورد استفاده، **شاخص کل قیمت مصرف‌کننده کل خانوارهای کشور**، با **سال پایه ۱۴۰۰=۱۰۰** است. شاخص مسکن یا نرخ تورم نقطه‌به‌نقطه جایگزین CPI کل نشده است.

از میانگین سالانه CPI استفاده می‌کنیم، نه شاخص اسفند. شاخص‌های ۱۴۰۰ تا ۱۴۰۲ از جدول ۷ گزارش مرکز آمار و شاخص ۱۴۰۳ از میانگین ۱۲ مقدار ماهانه همان مجموعه با گرد کردن به یک رقم اعشار گرفته شده‌اند. شاخص سال ۱۴۰۳ برابر ۲۷۱٫۷ است؛ ۲۱۵٫۷ **شاخص اسفند است و میانگین سالانه نیست.**



میانگین حساسی به قیمت‌های بسیار بزرگ حساس است. در کنار پاسخ اصلی، میانه حقیقی و میانگین پس از وینزور ۱٪ گزارش می‌شوند. وینزور یعنی مقادیر کمتر از صدک ۱ یا بیشتر از صدک ۹۹ را به همان آستانه برسانیم؛ ردیف‌ها حذف نمی‌شوند. برای مقایسه سال‌ها، آستانه مشترک از قیمت‌های اسمی تمام چهار سال محاسبه می‌شود. این یک **تحلیل حساسیت با معیار تغییر یافته** است، نه اثبات اشتباه بودن قیمت‌های خارج از آستانه و نه جایگزین مخفی میانگین اصلی. همچنین برای حساسیت به ابهام تاریخ ماهانه، میانگین با حذف مارس محاسبه می‌شود.

میانگین حقیقی در این نمونه از ۱۴۰۰ به ۱۴۰۱ افزایش، در ۱۴۰۲ کاهش و در ۱۴۰۳ دوباره افزایش دارد؛ روند یکنواخت نیست. برای ۱۴۰۰ فقط ۳ آگهی و برای ۱۴۰۱ فقط ۴۷ آگهی فروش قیمت‌دار وجود دارد؛ تقریباً تمام حجم نمونه در ۱۴۰۳ است. اختلاف بزرگ میانگین و میانه و تغییر نتیجه با کنترل مقادیر افراطی، حساسیت به کیفیت داده را نشان می‌دهد. از ۱۴۰۲ به ۱۴۰۳، برخلاف میانگین خام، میانه حقیقی و میانگین حقیقی وینزور شده کاهش پیدا می‌کنند. بنابراین این نمودار روند **میانگین آگهی‌های همین فایل** را نشان می‌دهد و مبنای کافی برای ادعای رشد واقعی کل بازار مسکن ایران نیست. ترکیب شهر، نوع ملک، متراژ و ماه‌های مشاهده شده ثابت نگه داشته نشده است و مبلغ آگهی نیز قیمت معامله قطعی نیست

8. ماتریس همبستگی را برای مبلغ قیمت، مترائ زمین، زیربنا، ظرفیت نفرات، تعداد اتاق‌ها و طول و عرض جغرافیایی رسم نمایید.




هفت متغیر در ماتریس وجود دارد: مبلغ قیمت، مترائ زمین، زیربنا، ظرفیت معمول نفرات، تعداد اتاق، طول و عرض جغرافیایی. «ظرفیت نفرات» به ستون `regular_person_capacity` نگاشت شده است؛ ظرفیت اضافه به آن جمع نشده است. ماتریس اصلی **Pearson** است و **Spearman** برای بررسی حساسیت به مقادیر پرت و روابط یکنواخت ارائه می‌شود.

برای هر جفت متغیر فقط ردیف‌هایی به کار می‌روند که همان دو مقدار موجود باشند (pairwise complete observations). شرط حداقل ۳۰ مشاهده برای گزارش ضریب اعمال می‌شود؛ همه جفت‌های قابل گزارش در این داده بسیار بیشتر از این تعداد مشاهده دارند. ظرفیت نفرات در اجاره موقت ثبت شده، ولی قیمت فروش معتبر در آگهی‌های فروش است؛ هیچ همپوشانی معتبر بین این دو وجود ندارد. بین ظرفیت نفرات و مترائ زمین نیز

همپوشانی وجود ندارد. این خانه‌ها **NA** هستند، نه صفر. حذف همه ردیف‌هایی که یکی از هفت متغیرشان خالی باشد، کل نمونه را از بین می‌برد.

Q8 | Spearman rank correlation (sensitivity)




Pairwise valid observations; NA = no valid overlap. Rooms are top-coded at 5.


در Pearson، همبستگی زمین و زیربنا حدود ۰/۳۷۳ و همبستگی ظرفیت نفرات و تعداد اتاق حدود ۰/۳۴۴ است. همبستگی خام قیمت و زیربنا حدود ۰/۰۵۲ و قیمت و تعداد اتاق حدود ۰/۰۱۴ است؛ این اعداد به تنهایی نبود رابطه را ثابت نمی‌کنند. در Spearman، قیمت و تعداد اتاق حدود ۰/۴۱۵، زیربنا و تعداد اتاق حدود ۰/۶۴۶ و ظرفیت نفرات حدود ۰/۴۹۷ هستند. اختلاف دو روش با حضور داده‌های افراطی و شکل غیرخطی رابطه سازگار است.


هر جفت ضریب ممکن است بر زیرجمعیت متفاوتی از آگهی‌ها محاسبه شده باشد؛ جدول تعداد مشاهدات برای همین منظور همراه نتیجه است. تعداد اتاق‌ها متغیر سقف‌گذاری شده است. ضریب پایین قیمت با طول/عرض جغرافیایی هم به معنای


بی‌اهمیت بودن مکان نیست؛ اثر شهر و محله را نمی‌توان با یک رابطه خطی سراسری با مختصات خلاصه کرد. همبستگی نیز رابطه علّی را اثبات نمی‌کند.




9. می‌خواهیم بررسی کنیم خانه‌هایی که دارای بالکن، آسانسور، نگهبان، باربیکیو و استخر هستند عمدتاً در کدام مناطق قرار دارند. با نمودار مناسب این موضوع را نشان دهید.












آزمون فرض (h1 to h4)

با توجه به رشد مهاجرت افراد از شهرهای کوچکتر به کلان‌شهرها و تراکم جمعیت در این نواحی، تصور می‌شود که میانگین مساحت خانه‌های مسکونی در کلان‌شهرها نسبت به شهرهای کوچک و روستاها کمتر است. آیا مجموعه داده این فرضیه را پشتیبانی می‌کند؟ (برای دسته‌بندی شهرها به کلان‌شهر و شهر کوچک می‌توانید از این مجموعه داده استفاده کنید).



در این تحلیل، **متراژ ساختمان (building_size)** بین دو گروه **کلان‌شهرها و شهرهای کوچک** مقایسه شده است. ابتدا برای کاهش تأثیر داده‌های پرت، با استفاده از روش **IQR** داده‌های پرت حذف شدند. سپس برای هر گروه، میانگین متراژ ساختمان محاسبه و دو آزمون آماری انجام شد.

در گروه کلان‌شهرها، میانگین متراژ ساختمان حدود **98.81 مترمربع** و در شهرهای کوچک حدود **104.58 مترمربع** به دست آمد. بنابراین، میانگین متراژ ساختمان در شهرهای کوچک در این نمونه بیشتر است.

در آزمون **Welch's t-test**، فرض صفر این بود که میانگین متراژ ساختمان در کلان‌شهرها بزرگ‌تر یا مساوی شهرهای کوچک است:

$$\bullet \quad t\text{-statistic} = -54.87$$

$$\bullet \quad p\text{-value} < 0.001$$

از آنجا که مقدار $p\text{-value}$ بسیار کمتر از سطح معناداری **0.05** است، فرض صفر رد می‌شود و شواهد آماری از این فرض حمایت می‌کند که **میانگین متراژ ساختمان در کلان‌شهرها کمتر از شهرهای کوچک است.**


برای بررسی بیشتر، آزمون **Mann–Whitney U** نیز انجام شد که به توزیع نرمال داده‌ها وابستگی کمتری دارد. نتیجه این آزمون نیز معنادار بود:

$$\bullet \quad U\text{-statistic} = 76,114,024,716.5$$

$$\bullet \quad p\text{-value} < 0.001$$

بنابراین، هر دو آزمون نتیجه یکسانی ارائه می‌دهند: **در داده‌های مورد بررسی، ساختمان‌های موجود در کلان‌شهرها به‌طور آماری معناداری متراژ کمتری نسبت به ساختمان‌های شهرهای کوچک دارند.**

معمولا این جمله را می‌شنویم که «قدیما خانه‌ها دلبازتر بود!» برای بررسی این فرضیه، آیا میانگین مساحت خانه‌های قدیمی‌ساخت نسبت به خانه‌های جدید ساخت بیشتر است؟ (خانه‌های قدیمی‌ساخت را خانه‌هایی در نظر بگیرید که قبل از سال ۹۶ ساخته شده‌اند).



در این تحلیل، **متراژ ساختمان (building_size)** بین دو گروه **خانه‌های قدیمی‌ساخت** و **خانه‌های جدیدساخت** مقایسه شده است. خانه‌هایی که سال ساخت آن‌ها کمتر از ۱۳۹۶ بوده در گروه قدیمی و خانه‌هایی با سال ساخت ۱۳۹۶ و بعد از آن در گروه جدید قرار گرفته‌اند.

برای کاهش تأثیر داده‌های پرت، ابتدا برای هر گروه به‌صورت جداگانه از روش **IQR** استفاده شد و مقادیر خارج از محدوده $1.5 \times IQR$ حذف شدند.

نتایج توصیفی نشان می‌دهد که میانگین متراژ خانه‌های قدیمی‌ساخت حدود **91.01 مترمربع** و میانگین متراژ خانه‌های جدیدساخت حدود **110.68 مترمربع** است. همچنین میانه متراژ در خانه‌های قدیمی **85 مترمربع** و در خانه‌های جدید **104 مترمربع** است. بنابراین، در داده‌های نمونه، خانه‌های جدیدساخت به‌طور متوسط متراژ بیشتری دارند.

برای بررسی آماری این تفاوت، آزمون **Mann-Whitney U** به دلیل غیرنرمال بودن توزیع داده‌ها انجام شد. فرض‌ها به شکل زیر تعریف شدند:

- **H₀**: میانگین/موقعیت توزیع متراژ خانه‌های قدیمی‌ساخت بزرگ‌تر یا مساوی خانه‌های جدیدساخت است.

- **H₁:** متراژ خانه‌های قدیمی‌ساخت بیشتر از خانه‌های جدیدساخت است.

نتیجه آزمون:

- **U-statistic = 37,123,786,259**

- **p-value = 1.00**

از آنجا که مقدار p-value بسیار بزرگ‌تر از سطح معناداری **0.05** است، **فرض صفر رد نمی‌شود**. در واقع، جهت اختلاف مشاهده‌شده کاملاً برخلاف فرض جایگزین است؛ یعنی داده‌ها نشان می‌دهند متراژ خانه‌های قدیمی‌ساخت کمتر از خانه‌های جدیدساخت است.


برای بررسی تکمیلی، آزمون **Welch's t-test** نیز انجام شد و نتیجه آن نیز با این مشاهده سازگار بود:

- **t-statistic = -212.18**

- **p-value = 1.00** برای آزمون یک‌طرفه با فرض $old > new$

بنابراین، در داده‌های مورد بررسی شواهد آماری از این فرض که خانه‌های قدیمی‌ساخت متراژ بیشتری از خانه‌های جدیدساخت دارند وجود ندارد. برعکس، آمار توصیفی نشان می‌دهد که خانه‌های جدیدساخت در این نمونه به‌طور محسوسی متراژ بیشتری دارند.

داشتن سند تجاری (یا هر نوع سند ملکی) در املاک به این معنی است که سند مالکیت معتبر، رسمی و قانونی برای ملک تجاری دارید. این سند نشان می‌دهد که شما صاحب قانونی ملک تجاری هستید و می‌توانید از حقوق مالکیت آن استفاده کنید. بررسی کنید که آیا داشتن سند تجاری (has_business_deed) بر میانگین قیمت فروش ملک تجاری ارتباط معناداری دارد؟



در این فرضیه بررسی شد که آیا وضعیت سند تجاری (business_deed) با قیمت آگهی‌های فروش املاک تجاری ارتباط دارد یا خیر. برای این منظور، آگهی‌های مربوط به commercial-sell با قیمت مثبت انتخاب شدند و آگهی‌هایی که وضعیت سند آنها نامشخص بود از تحلیل حذف شدند. در نهایت، قیمت املاک دارای سند تجاری و فاقد سند تجاری با استفاده از آزمون t ولج (Welch's t-test) مقایسه شد.

سطح معناداری آزمون برابر با ۰/۰۵ در نظر گرفته شد. نتیجه آزمون نشان داد که مقدار p-value برابر با ۰/۸۷۹۵ است. از آنجا که:

$$p = 0.8795 > 0.05$$

در سطح معناداری ۵ درصد، شواهد کافی برای رد فرض صفر وجود ندارد. بنابراین، در این نمونه تفاوت آماری معناداری بین میانگین قیمت آگهی‌های دارای سند تجاری و فاقد سند تجاری مشاهده نشد.

همچنین برای بررسی تأثیر مقادیر پرت، یک تحلیل حساسیت با Winsorization در محدوده صدک‌های ۱ و ۹۹ انجام شد. این بررسی به دلیل وجود مقادیر بسیار بزرگ در قیمت‌ها انجام گرفت؛ برای مثال، بیشترین قیمت ثبت‌شده در داده حدود ۱۰۰ تریلیون تومان بود. بنابراین بررسی پایداری نتیجه نسبت به مقادیر حدی اهمیت داشت.

در مجموع، بر اساس آزمون انجام‌شده، داده‌های این نمونه شواهد آماری کافی برای وجود تفاوت در میانگین قیمت املاک تجاری بر اساس وضعیت سند تجاری ارائه نمی‌کنند. این نتیجه به معنای اثبات برابری واقعی قیمت دو گروه نیست، بلکه نشان می‌دهد که با این داده‌ها و در سطح معناداری ۰/۰۵، تفاوت مشاهده‌شده از نظر آماری معنادار نیست.

در دسته‌بندی امکانات موجود در آگهی‌ها می‌توانیم آنها را به دو دسته‌ی امکانات لاکچری (استخر، باربیکیو، سونا، جکوزی) و امکانات غیر لاکچری تقسیم کنیم. فرضیه‌ی ما این است که میانگین مبلغ قیمت برای وجود ویژگی‌های لاکچری افزایش چشم‌گیری دارد. اما آیا این میانگین برای وجود امکانات غیرلاکچری نیز تفاوت معناداری دارد؟

h4

از هر گروه ۵۰۰۰ نمونه به صورت تصادفی انتخاب شد. ابتدا برای بررسی نرمال بودن توزیع قیمت‌ها از آزمون Shapiro-Wilk استفاده شد. مقدار p-value برای گروه لوکس برابر با 1.9983×10^{-95} و برای گروه غیرلوکس برابر با 1.1322×10^{-95} به دست آمد. از آنجا که هر دو مقدار بسیار کمتر از سطح معناداری ۰/۰۵ هستند، فرض نرمال بودن توزیع قیمت‌ها رد شد.

بنابراین، برای مقایسه دو گروه از آزمون ناپارامتری Mann-Whitney U استفاده شد.

فرضیه‌ها به صورت زیر تعریف شدند:

- H_0 : توزیع قیمت املاک لوکس بیشتر از توزیع قیمت املاک غیرلوکس نیست.
- H_1 : توزیع قیمت املاک لوکس بالاتر از توزیع قیمت املاک غیرلوکس است.

نتیجه آزمون به صورت زیر به دست آمد:

$$U = 15,112,245.5$$


$$p\text{-value} = 1.6567 \times 10^{-73}$$

از آنجا که مقدار p-value بسیار کمتر از ۰/۰۵ است، فرض صفر رد می‌شود. بنابراین، در این نمونه شواهد آماری معناداری وجود دارد که نشان می‌دهد توزیع قیمت املاک دارای حداقل یکی از امکانات لوکس، بالاتر از توزیع قیمت املاک فاقد این امکانات است.


مسئله ۱: ساخت سیستم توصیه‌گر (p1 to p3)

بخش ۱)


حال الگوریتم خوشه‌بندی K-means را تنها بر حسب با ۱۰ خوشه برای این مجموعه داده اجرا کنید. سپس ابتدا مختصات جغرافیایی را به فرمت UTM درآورید و برای دو ویژگی قیمت و مختصات UTM یک اسکترپلات رسم کنید. بر روی اسکتر پلات رسم‌شده مشخص کنید کدام نقاط مربوط به کدام خوشه هستند و مرکز هر خوشه را نیز رسم کنید. به انتخاب رنگ، مارکر، نام‌گذاری محورها و به‌طور کلی قابل درک بودن تصویر دقت داشته باشید.




کلاستربندی جامع



کلاستربندی مربوط به داده های فقط مربوط به اجاره




کلاستربندی مربوط به داده های فقط مربوط به فروش



کلاستر بندی مربوط به داده های فقط مربوط به اجاره روزانه

بخش ۲


پس از آن الگوریتم K-means را برای k هایی از ۱ تا ۲۰ اجرا کرده و با محاسبه‌ی مجموع مجزورات درون خوشه‌ای (*Within-Cluster Sum of Square*)، مقدار مناسبی برای هایپرپارامتر k انتخاب کنید. توجه کنید که بخش زیادی از نمره‌ی این بخش مربوط به نحوه‌ی انتخاب مقدار k است و چنانچه روش‌های تدریس‌شده و معمول پاسخگوی حل مسئله نبود، انتظار می‌رود با جستجو و مطالعه‌ی بیشتر، روشی مناسب برای رفع چالش‌های احتمالی پیشنهاد دهید.



مقدار **WCSS** برای تعداد خوشه‌های مختلف، از ۱ تا ۲۰، محاسبه شده است. با افزایش تعداد خوشه‌ها، WCSS همیشه کاهش پیدا می‌کند؛ اما نکته مهم این است که بعد از یک نقطه، اضافه کردن خوشه‌های بیشتر بهبود زیادی ایجاد نمی‌کند.

در نمودار، این تغییر شیب یا همان **Elbow (آرنج)** تقریباً در محدوده **K=8 تا K=9** دیده می‌شود.

بنابراین روش **Elbow** پیشنهاد می‌کند که تعداد خوشه‌ها حدود **۹ یا ۸** باشد.



روش دوم، **Silhouette Score** است که میزان مناسب بودن جداسازی خوشه‌ها را بررسی می‌کند.

مقدار Silhouette معمولاً بین **-1** و **+1** قرار دارد و مقدار بالاتر نشان‌دهنده جداسازی بهتر و ساختار مناسب‌تر خوشه‌ها است.


طبق نمودار:


در **K=9** مقدار Silhouette حدود **0.182** است و بیشترین مقدار را دارد.

در **K=8** مقدار آن حدود **0.166** است.

بنابراین، بر اساس **K=9**، **Silhouette Score** بهترین مقدار است

مثال کلاستر بندی 8 تایی





با افزایش ϵ ، تعداد خوشه‌ها عموماً کاهش پیدا می‌کند، زیرا نقاط بیشتری به یکدیگر متصل می‌شوند. همچنین با افزایش $\min_samples$ ، تشکیل خوشه سخت‌تر شده و تعداد خوشه‌های شناسایی‌شده معمولاً کاهش می‌یابد. در مقادیر بسیار کوچک ϵ ، تعداد زیادی خوشه کوچک ایجاد می‌شود، در حالی که در مقادیر بزرگ مانند $\epsilon=0.7$ و 0.8 تقریباً تمام داده‌ها به یک یا دو خوشه متصل می‌شوند. در تنظیم $\epsilon=0.5$ و $\min_samples=10$ ، DBSCAN سه خوشه شناسایی کرده است که برای بررسی تفاوت‌های مکانی و قیمتی بین گروه‌های املاک مورد استفاده قرار گرفته‌اند.

مسئله ۲: پیش‌بینی (f1 to f4)



